

Diccionario de variables

Archivo de modelado `enmt_clean.csv`

Percepción del transporte público en México

1. Descripción general

Archivo derivado de los microdatos de la Encuesta Nacional de Movilidad y Transporte (ENMT) del Instituto de Investigaciones Jurídicas de la UNAM.

1,117 observaciones $\times$ **17 variables**. Todas categóricas, sin valores faltantes. El archivo original comprende 1,191 informantes y 698 variables; este es el resultado del script de limpieza en Python. La columna `con1` es el identificador del informante en el archivo original y se lee como `row.names`.

Advertencia sobre el medio de transporte. La variable de modo se construye en *dos* etapas y el archivo guarda la intermedia. El CSV contiene la columna `modo_principal`, con ocho niveles; el script de R la colapsa a los cuatro niveles de `modo_usado` que se documentan más adelante, y elimina la original. Este diccionario describe `modo_usado`, que es la variable que entra a la red, no la columna tal como aparece en el archivo. La sección de notas de construcción detalla ambas etapas.

2. Resumen de variables

Variable	Descripción	Niveles
<i>Contexto territorial</i>		
region	Región del país	4
tam_loc	Tamaño de localidad	4
tiene_sistema_tren	Sistema ferroviario urbano en la entidad	2
<i>Perfil sociodemográfico</i>		
sexo	Sexo	2
edad	Grupo etario	6
escolaridad	Nivel de estudios alcanzado	5
ingreso_familiar	Ingreso del hogar en múltiplos de SM	8
condicion_actividad	Condición de actividad económica	2
<i>Movilidad</i>		
tiene_auto	Disponibilidad de automóvil en el hogar	2
modo_usado [†]	Medio de transporte predominante	4
<i>Evaluación del servicio</i>		
tp_eficiente	El transporte público es eficiente	2
tp_rapido	El transporte público es rápido	2
tp_barato	El transporte público es barato	2
tp_seguro	El transporte público es seguro	2
tp_comodo	El transporte público es cómodo	2
<i>Percepción ambiental</i>		
contamina_su_modos	Contaminación percibida del modo propio	4
contamina_aire	Contaminación percibida del aire	4

Tabla 1: Las 17 variables del archivo de modelado, organizadas en cuatro bloques. [†] En el CSV esta columna se llama modo_principal y tiene ocho niveles; modo_usado se deriva de ella en R.

3. Distribución de frecuencias

Variable	Nivel	n	%
<i>Contexto territorial</i>			
region	region_1	338	30.3
	region_2	291	26.1
	region_3	272	24.4
	region_4	216	19.3
tam_loc	100mil_mas	588	52.6
	15mil_99999	204	18.3
	2500_14999	190	17.0
	menos_2500	135	12.1

continúa

Variable	Nivel	n	%
tiene_sistema_tren	no	716	64.1
	si	401	35.9
<i>Perfil sociodemográfico</i>			
sexo	hombre	603	54.0
	mujer	514	46.0
edad	18-24	187	16.7
	25-34	279	25.0
	35-44	271	24.3
	45-54	166	14.9
	55-64	111	9.9
	65+	103	9.2
escolaridad	ninguna	135	12.1
	primaria	172	15.4
	secundaria	433	38.8
	preparatoria	295	26.4
	universidad	82	7.3
ingreso_familiar	menos_1sm	19	1.7
	1-2sm	135	12.1
	2-3sm	171	15.3
	3-4sm	154	13.8
	4-5sm	103	9.2
	5-6sm	70	6.3
	mas_6sm	223	20.0
	no_declaro	242	21.7
condicion_actividad	ocupado	662	59.3
	no_ocupado	455	40.7
<i>Movilidad</i>			
tiene_auto	no	841	75.3
	si	276	24.7
modo_usado	masivo	62	5.6
	concesionado	471	42.2
	particular	242	21.7
	otro	342	30.6
<i>Evaluación del servicio</i>			
tp_eficiente	eficiente	706	63.2
	ineficiente	411	36.8
tp_rapido	rapido	605	54.2
	lento	512	45.8
tp_barato	barato	549	49.1

continúa

Variable	Nivel	n	%
tp_seguro	caro	568	50.9
	seguro	489	43.8
	inseguro	628	56.2
tp_comodo	comodo	499	44.7
	incomodo	618	55.3
<i>Percepción ambiental</i>			
contamina_su_modo	no_contamina	134	12.0
	poco	350	31.3
	algo	400	35.8
	mucho	233	20.9
contamina_aire	nada	104	9.3
	poco	379	33.9
	algo	411	36.8
	mucho	223	20.0

Tabla 2: Distribución de frecuencias de las 17 variables ($n = 1,117$).

4. Notas de construcción

Cuatro variables no se leen directamente del cuestionario y sus decisiones de construcción condicionan cualquier reanálisis.

tiene_sistema_tren

Se derivó de la entidad federativa, que después se descartó del modelo. Los usuarios cotidianos de tren urbano se concentran en la Ciudad de México, el Estado de México, Nuevo León y Jalisco, y el indicador cubre también al 96 % de los usuarios de BRT y transporte eléctrico. Permite comparar usuarios de transporte masivo y de otros modos *dentro* de las ciudades donde el masivo existe, separando el efecto de usar el metro del efecto de residir en una metrópoli que cuenta con él.

ingreso_familiar: el nivel no_declaro

En el archivo original el valor 0 corresponde a la no respuesta y no al ingreso nulo. Notamos que el valor 1, que según el diccionario de la encuesta corresponde a no respuesta, no apareció, así que asumimos que el 0 se refiere al 1 y no que su ingreso familiar sea literalmente 0.

modo_usado: una construcción en dos etapas

El medio de transporte predominante no se lee del cuestionario: se construye en dos pasos, ejecutados en herramientas distintas. El archivo de modelado guarda la etapa intermedia.

Primera etapa (Python). Los modos del cuestionario se agrupan en ocho familias, que se guardan en la columna `modo_principal` del CSV. Como el cuestionario registra frecuencia de uso y no un ordenamiento, asignar una familia predominante por persona requirió una regla de desempate: entre

las familias usadas cotidianamente se prefieren aquellas con motivo de viaje obligado, como trabajo o estudios; si el empate persiste se aplica una jerarquía por compromiso; quien no reporta modo cotidiano se asigna a la categoría residual **ninguno**.

Segunda etapa (R). Las ocho familias se colapsan a los cuatro niveles de **modo_usado** y **modo_principal** se elimina del marco de datos.

modo_principal	modo_usado	n
masivo	masivo	62
camion	concesionado	327
colectivo	concesionado	144
particular	particular	242
ninguno	otro	221
demanda	otro	66
otros	otro	31
activo	otro	24

Tabla 3: Correspondencia entre las ocho familias del CSV y los cuatro niveles que entran a la red.

La reducción de ocho a cuatro niveles responde a dimensionalidad. Con las ocho familias, las categorías menos frecuentes, por ejemplo, **activo** con 24 casos y **otros** con 31, generan celdas con frecuencias insuficientes para estimar de forma estable las tablas de probabilidad condicional de los nodos que dependen del modo. Con cuatro niveles la categoría más pequeña, **masivo**, conserva 62 casos.